

Universidad de Antioquia – Facultad de Ingeniería
Anteproyecto de Proyecto Integrador – Semestre 2026-2

Comparación de redes neuronales convolucionales clásicas y cuánticas (CNN y QCNN) para la clasificación de señales ECG: prototipo de monitorización cardiovascular

Programa y modalidad Ingeniería de Sistemas – modalidad presencial
Código, asignatura y grupo 2508700 – Proyecto integrador 1 – Grupo 1
Tipo de proyecto Desarrollo
Profesor Javier Fernando Botia Valderrama – javier.botia@udea.edu.co

Estudiantes	Documento	Correo electrónico
Juan José Barrientos Salazar	C.C. 1025883507	juanj.barrientos@udea.edu.co
Brayan Stiven Tobón Foronda	C.C. 1033426121	bstiven.tobon@udea.edu.co
Didian Alejandro Valencia Ruíz	C.C. 1000099616	didian.valencia@udea.edu.co

Resumen

El electrocardiograma (ECG) es el examen de primera línea para detectar alteraciones del ritmo y de la conducción cardíaca, y su lectura se apoya en la morfología de cinco ondas y tres intervalos de referencia. Este proyecto de desarrollo construye un prototipo de software que clasifica segmentos de ECG y compara, sobre los mismos datos y la misma partición, una red neuronal convolucional unidimensional (CNN 1-D) como referencia y una red neuronal convolucional cuántica (QCNN) ejecutada en simulador. La clasificación inicial es binaria — segmento normal frente a anormal— y podrá extenderse a un esquema multiclase si el tiempo del semestre lo permite. La comparación considera exactitud, precisión, sensibilidad, F1 y matriz de confusión, y añade tres descriptores del modelo cuántico: profundidad, ancho y número de compuertas del circuito. El desarrollo se organiza con Shape Up, en ciclos de tres semanas con apetito fijo. El sistema tiene fines académicos y no constituye una herramienta de diagnóstico médico.

Palabras clave: electrocardiograma; clasificación de señales; redes neuronales convolucionales; aprendizaje automático cuántico; QCNN; profundidad de circuito.

Planteamiento del problema

Las enfermedades cardiovasculares son la principal causa de muerte en el mundo y el ECG sigue siendo la prueba más accesible para detectarlas a tiempo. El cuello de botella no es adquirir la señal, sino interpretarla: un registro Holter de 24 horas contiene alrededor de cien mil latidos, y revisarlos exige personal entrenado y tiempo que los servicios clínicos rara vez tienen.

Las redes convolucionales resuelven buena parte de ese problema con precisión comparable a la de un especialista (Hannun et al., 2019), a costa de modelos con cientos de miles de parámetros. En paralelo, el aprendizaje automático cuántico propone arquitecturas como la QCNN (Cong et al., 2019), cuyo número de parámetros crece de forma logarítmica con el tamaño de la entrada. La evidencia disponible tiene tres limitaciones para quien deba decidir si adoptarlas: casi todos los experimentos usan imágenes de referencia como MNIST (Hur et al., 2022) y no señales unidimensionales; las comparaciones con modelos clásicos no siempre ocurren en condiciones equivalentes; y el costo del circuito pocas veces se reporta junto con el desempeño, aunque es lo que determina si el modelo podría correr en hardware real.

El problema que aborda el proyecto es la ausencia de una comparación controlada y reproducible entre una CNN y una QCNN sobre una misma tarea de clasificación de ECG, presentada de modo que el desempeño y el costo del circuito puedan leerse juntos. La pregunta que orienta el trabajo es: ¿qué desempeño y qué costo de circuito alcanza una QCNN simulada frente a una

CNN 1-D equivalente en la clasificación binaria de segmentos de ECG? El alcance es académico: la parte cuántica se ejecuta en simulador, no se usan equipos médicos y el prototipo no emite diagnósticos.


Revisión bibliográfica y marco teórico

El ECG y la morfología de sus ondas

El ECG registra la actividad eléctrica del corazón como una secuencia periódica de deflexiones cuya nomenclatura y rangos de referencia están estandarizados (Kligfield et al., 2007). Un punto de partida útil para el trabajo técnico es que ninguna onda es patológica en sí misma: las cinco están siempre presentes en un trazado normal, y lo anormal es un cambio de forma, amplitud, dirección o duración respecto de esos rangos. Un clasificador, por tanto, aprende desviaciones morfológicas y temporales dentro de un patrón que se repite.

Figura 1

Complejo ECG normal con las cinco ondas y los tres intervalos principales



Nota. Trazado sintético de elaboración propia; rangos según Kligfield et al. (2007).

Tabla 1

Componentes del ECG y sus valores de referencia

Componente	Qué representa	Referencia normal
Onda P	Despolarización auricular	< 0,12 s; < 2,5 mm; positiva en II
Complejo QRS	Despolarización ventricular	< 0,12 s
Segmento ST	Meseta con el ventrículo despolarizado	Isoeléctrico
Onda T	Repolarización ventricular	Asimétrica; igual dirección del QRS
Onda U	Repolarización tardía (Purkinje)	Pequeña o ausente; normal si < 25 % de T
Intervalo PR	Conducción aurículo-ventricular	120 a 200 ms
Intervalo QT	Despolarización y repolarización ventricular	350 a 450 ms

Las alteraciones se leen componente por componente. Una onda P ausente sobre una línea de base irregular indica fibrilación auricular y en dientes de sierra, flutter. Un QRS de más de 120 ms apunta a bloqueo de rama, una onda Q patológica a un infarto antiguo y una onda delta a Wolff-Parkinson-White. El segmento ST es el grupo clínicamente más urgente: su elevación acompaña al infarto agudo con oclusión y su descenso a la isquemia. La onda T invertida se asocia a isquemia, alta y picuda a hiperpotasemia y plana a hipopotasemia; la onda U prominente, a hipopotasemia; y un PR mayor a 200 ms a bloqueo AV de primer grado. Las bases públicas anotadas siguen esta taxonomía, lo que permite mapear cada clase del clasificador a un hallazgo morfológico.

Estos rangos tienen consecuencias de diseño: la ventana debe contener el complejo completo —P, QRS, T y, cuando es visible, U—, lo que fija una longitud de 0,6 a 0,8 s alrededor del pico R; el carácter isoelectrico del ST obliga a corregir la deriva de la línea de base antes de normalizar, porque un desplazamiento artificial imita un hallazgo patológico; y la onda U acota el filtrado, pues un pasa-bajas agresivo la elimina con el ruido.

Clasificación automática de ECG con redes convolucionales

Kiranyaz et al. (2016) mostraron que una CNN unidimensional aplicada directamente sobre la señal, sin extracción manual de características, clasifica latidos en tiempo real con arquitecturas compactas. Hannun et al. (2019) escalaron el enfoque a una red profunda entrenada con 91.232 registros ambulatorios y alcanzaron un desempeño comparable al de cardiólogos certificados. Los conjuntos de referencia, distribuidos por PhysioNet, son MIT-BIH (Moody y Mark, 2001), con anotación latido a latido, y PTB-XL (Wagner et al., 2020), de doce derivaciones. Las dos dificultades recurrentes son el desbalance de clases y la necesidad de particionar por paciente.

QCNN y aprendizaje automático cuántico

Cong et al. (2019) propusieron la QCNN trasladando la convolución y el agrupamiento a circuitos cuánticos parametrizados: unitarias de dos qubits con parámetros compartidos como filtro y medición parcial de qubits como agrupamiento. Como en un circuito cuántico no puede aplicarse retropropagación, el entrenamiento usa la regla de desplazamiento de parámetros (Mitarai et al., 2018). Schuld et al. (2020) formalizaron estos circuitos como clasificadores y Hur et al. (2022) los evaluaron sobre datos clásicos con buena exactitud y pocos parámetros libres, ventajas limitadas por la etapa actual del hardware (Preskill, 2018) y por la entrenabilidad en circuitos profundos.

Sim et al. (2019) establecieron que un circuito parametrizado debe caracterizarse no solo por su desempeño, sino por descriptores estructurales de costo: profundidad, número de qubits y número de operaciones, en particular las de dos qubits. Ahí está el aporte de este proyecto: reportar el costo del circuito junto con las métricas de clasificación, sobre una señal unidimensional y en condiciones idénticas para los dos modelos.

Codificación de los datos clásicos en estados cuánticos

El eslabón que une la señal con el circuito es la codificación, y de ella depende el costo del modelo. La codificación por ángulos asigna cada característica al ángulo de una rotación monoqubit (R_x , R_y o R_z), con relación uno a uno entre características y qubits: es poco profunda, pero el ancho crece con la longitud de la ventana. La codificación por amplitud empaqueta N características en las amplitudes de un estado de $\log_2(N)$ qubits, con el compromiso inverso: eficiente en qubits y costosa en profundidad de preparación. La codificación en base se descarta por tratarse de una señal continua. Sobre el estado codificado actúan los mapas de características cuánticos —circuitos parametrizados con capas de entrelazamiento, como ZFeatureMap y ZZFeatureMap—, que proyectan los datos a un espacio de Hilbert de alta dimensión y son el mecanismo por el que el modelo introduce no linealidad (Havlíček et al., 2019; Schuld y Killoran, 2019). Como el simulador limita los qubits, la ventana se reduce antes con métodos clásicos —PCA, autoencoders o características latentes—: elegir la codificación es elegir un punto entre complejidad espacial (qubits) y temporal (profundidad y compuertas de dos qubits).

Objetivos

Objetivo general

Desarrollar un prototipo de software que integre una CNN 1-D y una QCNN simulada para la clasificación binaria de segmentos de ECG, y que permita comparar su desempeño y su costo de circuito bajo condiciones experimentales equivalentes. Los verbos siguen la taxonomía de Bloom revisada (Anderson y Krathwohl, 2001) y el nivel cognitivo se indica entre paréntesis.

Objetivos específicos

- Preparar un conjunto de segmentos de ECG a partir de una base pública anotada, con filtrado, normalización, segmentación por latido y partición estratificada reproducible. (Aplicar)
- Implementar una CNN 1-D de referencia sobre ese conjunto, documentando arquitectura, hiperparámetros y curvas de entrenamiento. (Aplicar)

- Diseñar e implementar una QCNN en simulador, contrastando la codificación por ángulos y por amplitud y definiendo el mapa de características, las capas de convolución y agrupamiento y la estrategia de optimización. (Crear)
- Integrar ambos modelos en un prototipo que permita cargar una señal, visualizarla, ejecutar el análisis y consultar el resultado de cada modelo. (Crear)
- Contrastar los dos modelos sobre la misma partición mediante exactitud, precisión, sensibilidad, F1 y matriz de confusión, y caracterizar la QCNN por profundidad, ancho y compuertas. (Analizar)
- Valorar las limitaciones del enfoque cuántico simulado en tiempo de cómputo, escalabilidad y estabilidad del entrenamiento, y formular recomendaciones para trabajos futuros. (Evaluar)

Metodología

El proyecto es de desarrollo con componente experimental y se gestiona con Shape Up (Singer, 2019). La elección es práctica: el equipo son tres estudiantes con horarios distintos, y una metodología basada en ceremonias diarias costaría más coordinación de la que aporta. Shape Up fija el tiempo y ajusta el alcance a él, no al revés.

- **Apetito fijo:** ciclos de tres semanas con una semana de estabilización (cool-down) para documentación y deuda técnica.
- **Shaping previo:** cada ciclo inicia con un pitch de una página —problema, apetito, solución esbozada, límites y riesgos— revisado con el profesor.
- **Scopes verticales:** unidades que una persona termina de extremo a extremo, con seguimiento por hill chart. Si un scope no se termina, no extiende el ciclo: vuelve a la mesa de apuestas.


Datos, modelos y métricas

La base de datos se decide al inicio del primer ciclo entre MIT-BIH y PTB-XL según cuatro criterios: frecuencia de muestreo, número de registros, taxonomía de etiquetas y disponibilidad de anotación latido a latido. El preprocesamiento comprende filtrado pasa-banda de 0,5 a 40 Hz, normalización por registro, detección del pico R y segmentación en ventanas que preserven el complejo completo según la Tabla 1. La partición es estratificada, separada por paciente y con semilla fija: ambos modelos usan la misma.

La CNN 1-D actúa como modelo de referencia, con bloques de convolución, normalización por lotes y agrupamiento. La QCNN reduce primero la ventana con PCA, de unos 250 puntos a entre 8 y 16 componentes, para ajustarla a los qubits del simulador. La codificación por defecto del prototipo es por ángulos, con rotaciones R_y y una componente por qubit, y se contrasta con la codificación por amplitud, que usa $\log_2(N)$ qubits a cambio de un circuito de preparación más profundo. Sobre el estado codificado se aplica un mapa de características tipo ZZFeatureMap para introducir entrelazamiento, luego las capas de convolución y agrupamiento, y la lectura es el valor esperado de un observable. La evaluación reporta dos familias de métricas: de desempeño —exactitud, precisión, sensibilidad, F1, matriz de confusión y tiempo de inferencia, con tres semillas— y de costo del circuito para la QCNN: profundidad (capas de compuertas en el camino crítico), ancho (qubits) y número de compuertas de uno y dos qubits.

Figura 2

Flujo experimental y de integración del prototipo



Nota. Elaboración propia. Las dos ramas comparten datos, partición y métricas.

Cronograma

Tabla 2

Cronograma por ciclos de trabajo, semestre 2026-2

Ciclo	Fechas	Foco y scopes	Entregable verificable
Shaping	26–31 ago.	Pitch del proyecto, definición del alcance y redacción del anteproyecto	Anteproyecto radicado
Ciclo 1	1–19 sep.	Selección de la base, ingesta, filtrado, normalización, segmentación y partición	Conjunto de datos versionado y script reproducible
Ciclo 2	28 sep.–17 oct.	CNN 1-D de referencia, características para la vía cuántica y esqueleto de la interfaz	CNN entrenada con métricas y curvas
Ciclo 3	20 oct.–7 nov.	QCNN en simulador: PCA, comparación de codificación por ángulos (por defecto) y por amplitud, e integración de los dos modelos	QCNN funcional y prototipo integrado
Ciclo 4	10–16 nov.	Comparación experimental, pruebas de extremo a extremo e informe final	Resultados consolidados e informe (16 de noviembre)

Presupuesto global

Tabla 3

Presupuesto global estimado (pesos colombianos)

Rubro	Base de cálculo estimada	Valor (COP)
Talento humano	3 estudiantes × 8 h/semana × 12 semanas × \$35.000/h	10.080.000
Asesoría docente	2 h/semana × 12 semanas × \$90.000/h	2.160.000
Equipos y conectividad	3 equipos × \$260.000/mes de uso × 3 meses	2.340.000
Cómputo en la nube	60 h de GPU y simulación × \$12.000/h	720.000
Papelería y divulgación	Impresión del informe y póster de sustentación	150.000
Imprevistos	5 % del subtotal	772.500
Total		16.222.500

Nota. Valores estimados con fines académicos; no corresponden a una ejecución presupuestal real. El software y las bases de datos empleadas son de acceso abierto, con costo cero.

Bibliografía

- Anderson, L. W., y Krathwohl, D. R. (Eds.). (2001). A taxonomy for learning, teaching, and assessing: A revision of Bloom's taxonomy of educational objectives. Longman.
- Cong, I., Choi, S., y Lukin, M. D. (2019). Quantum convolutional neural networks. *Nature Physics*, 15(12), 1273–1278. <https://doi.org/10.1038/s41567-019-0648-8>
- Hannun, A. Y., Rajpurkar, P., Haghighpanahi, M., Tison, G. H., Bourn, C., Turakhia, M. P., y Ng, A. Y. (2019). Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. *Nature Medicine*, 25(1), 65–69. <https://doi.org/10.1038/s41591-018-0268-9>
- Havlíček, V., Córcoles, A. D., Temme, K., Harrow, A. W., Kandala, A., Chow, J. M., y Gambetta, J. M. (2019). Supervised learning with quantum-enhanced feature spaces. *Nature*, 567(7747), 209–212. <https://doi.org/10.1038/s41586-019-0980-2>
- Hur, T., Kim, L., y Park, D. K. (2022). Quantum convolutional neural network for classical data classification. *Quantum Machine Intelligence*, 4(1), artículo 3. <https://doi.org/10.1007/s42484-021-00061-x>
- Kiranyaz, S., Ince, T., y Gabbouj, M. (2016). Real-time patient-specific ECG classification by 1-D convolutional neural networks. *IEEE Transactions on Biomedical Engineering*, 63(3), 664–675.
- Kligfield, P., Gettes, L. S., Bailey, J. J., Childers, R., Deal, B. J., Hancock, E. W., ... Wagner, G. S. (2007). Recommendations for the standardization and interpretation of the electrocardiogram: Part I. *Circulation*, 115(10), 1306–1324. <https://doi.org/10.1161/CIRCULATIONAHA.106.180200>
- Mitarai, K., Negoro, M., Kitagawa, M., y Fujii, K. (2018). Quantum circuit learning. *Physical Review A*, 98(3), 032309. <https://doi.org/10.1103/PhysRevA.98.032309>
- Moody, G. B., y Mark, R. G. (2001). The impact of the MIT-BIH Arrhythmia Database. *IEEE Engineering in Medicine and Biology Magazine*, 20(3), 45–50.
- Preskill, J. (2018). Quantum computing in the NISQ era and beyond. *Quantum*, 2, 79. <https://doi.org/10.22331/q-2018-08-06-79>
- Schuld, M., y Killoran, N. (2019). Quantum machine learning in feature Hilbert spaces. *Physical Review Letters*, 122(4), 040504. <https://doi.org/10.1103/PhysRevLett.122.040504>
- Schuld, M., Bocharov, A., Svore, K. M., y Wiebe, N. (2020). Circuit-centric quantum classifiers. *Physical Review A*, 101(3), 032308. <https://doi.org/10.1103/PhysRevA.101.032308>
- Sim, S., Johnson, P. D., y Aspuru-Guzik, A. (2019). Expressibility and entangling capability of parameterized quantum circuits for hybrid quantum-classical algorithms. *Advanced Quantum Technologies*, 2(12), 1900070. <https://doi.org/10.1002/qute.201900070>
- Singer, R. (2019). Shape up: Stop running in circles and ship work that matters. Basecamp.
- Wagner, P., Strodthoff, N., Boussejot, R.-D., Kreiseler, D., Lunze, F. I., Samek, W., y Schaeffter, T. (2020). PTB-XL, a large publicly available electrocardiography dataset. *Scientific Data*, 7, 154. <https://doi.org/10.1038/s41597-020-0495-6>